關鍵字預測股價漲跌模型與回測模型分析

經濟三 林倩伊 經濟三 林羿呈 經濟三 林柏呈
經濟三 黃榆婷 工管三 謝睿穎 工管三 姚奕弘

大數據與商業分析 期中報告 第一組

Agenda

（一）	選股邏輯
（二）	資料前處理
（三）	分類器模型之建構與表現
（四）	回測模型分析
（五）	Recap

（一）選股邏輯

篩選條件:

- 市值排名前段之公司，可能是較受歡迎的投資標的
- 在2022 - 2024年間之股價有明顯波動
- 聲量大、討論度足，總文章數超過 10000 篇

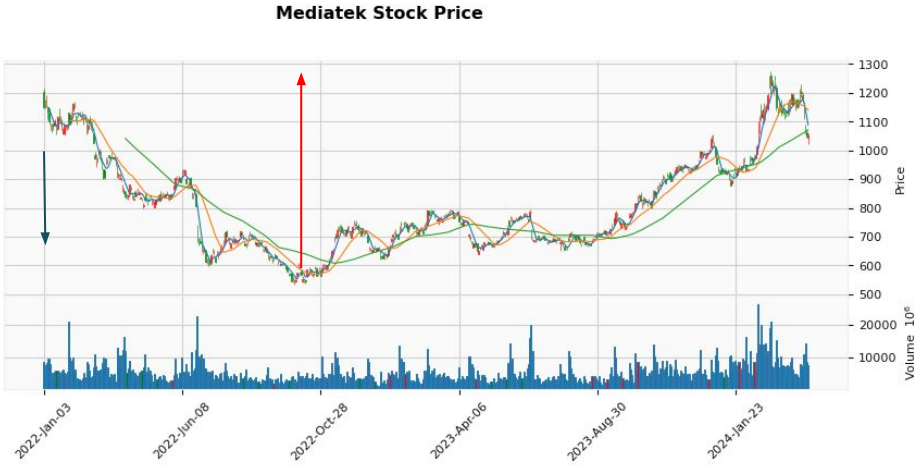

選擇**聯發科 (2454)** 作為此次的分析標的

- 總文章:13K +
- 漲跌幅超過 100%

(二)資料前處理

資料前處理 (1)

- 首先需要針對股價進行處理，我們希望透過設定參數 N/K，即以 D + N 天後的股價上漲 K% 定義何為“漲” 或 “跌”
- 問題：不知道 N/K 之最佳值為何？
- 解決方式：決定透過設定 ※N = [1, 3, 5] 與 ※K = [0%, 1%, 3%, 5%] 來生成12種不同的資料集，並由模型實測觀察結果再選擇我們覺得最合適的定義方式，可能的考慮條件包括：資料筆數的多寡, Percision/recall, F1 score, AUC...

※ 舉例來說：N = 1, K = 0% 即1天後只要有漲就定義為漲 1%即要漲超過1%才算漲，後續「資料集名稱」皆會以「K%ND」表示

Demo：價格資料處理方式

使用Excel把價格資料應不同漲幅(%)條件，按N天排序整理如下，下圖為設定 ±5%才算漲/跌之版本，總共會針對股價處理預先製作四份(0%,1%,3%,5%)如下圖格式的資料：

post_time	Open	Close	Volume	Difference 1D	D+1	Difference 3D	D+3	Difference 5D	D+5
2022-02-21	1115	1130	3088278						
2022-02-22	1115	1110	4725273	-1.80%	平				
2022-02-23	1110	1120	3540429	0.90%	平				
2022-02-24	1095	1060	7867454	-5.40%	跌				
2022-02-25	1075	1085	7091202	2.40%	平				
2022-02-26	1105	1100	5420606	1.40%	平	-1.80%	平	-2.70%	平
2022-02-27	1105	1080	3632197	-1.80%	平	1.90%	平	-2.70%	平
2022-02-28	1085	1080	3799148	0.00%	平	-0.50%	平	-3.60%	平
2022-03-01	1060	1025	6254448	-5.10%	跌	-6.80%	跌	-3.30%	平
2022-03-02	985	972	10685986	-5.20%	跌	-10.00%	跌	-10.40%	跌

程式碼可以讀取 D+N 的欄位來分開漲跌的文章
(可結合適當的檔名命名製作迴圈自動化讀取資料過程)

資料前處理 (2)

- 針對已經標記好漲跌之文章進行斷詞和移除停用詞
  - 停用詞列表中也存在著部分人工判斷可歸類為停用詞的字彙:如年份 /日期
- 對前頁提及12種不同天數/漲幅資料，將漲文與跌文分開後進行 Term frenquency (TF) 和 Document Frenquency (DF) 卡方值的計算，再分別提取漲跌兩類 TF 和 DF 卡方值排名前200名之字彙，最後建立 termset字典，存取所有不重複之字彙，以此建立向量模型:

Post time	title	content	label	content cut	A字	B字
…	…	…	漲	高盛 證券 …	※frequency(A)	frequency(B)
…	…	…	跌	…	…	…

…

※ frequency(A):代表A字在該文章出現的頻率，B同理

資料前處理 (3)

- 同時也針對對向量模型所需資料進行降維處理，使用主成分分析法（ PCA），以其中一資料集（5%1D）為例，可以和未降維之資料進行比較

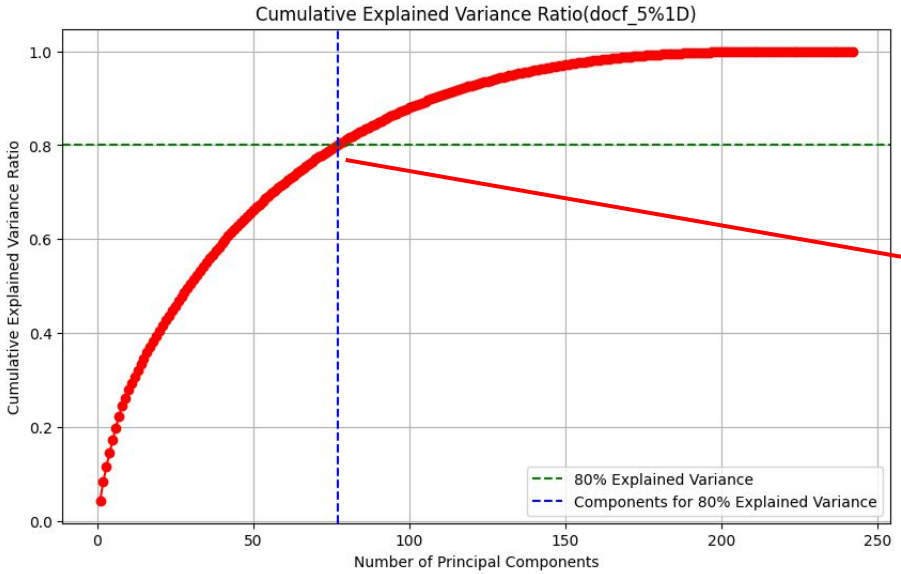

約累計至第77個主成份時，可以解釋80%的原始資料。將資料從近250維降至77維

(三)分類模型之建構與表現

分類模型

- 將看漲和看跌的文章分成訓練和測試資料兩類
  - Training - 80% , Testing - 20%
- 將資料餵入不同模型，並以 VotingClassifier 整合不同模型的預測結果
  - 8種分類模型：Naïve Bayes, KNN, SVM linear, SVM rbf, Decision Tree, Random Forest, XGboost, Logistic Regression
- 模型分類結果比較
  - 計算各模型 Confusion Matrix, Accuracy, Precision, Recall, F1-Score
  - 繪製 ROC Curve , 計算 AUC
  - 12種不同的資料集 (N=3, K=4)，乘以2種資料向量化（tf 卡方or df卡方）的方式，再乘以17種模型和投票法（無PCA共9種；PCA共8種，無NB），12 * 2 * 17，最終共產生408種結果

分類模型

- 最終以5%1D-TF-PCA 資料集表現最佳

Voting	真實為漲	真實為跌
預測為漲	20	3
預測為跌	6	20

Logistic Regression	真實為漲	真實為跌
預測為漲	22	1
預測為跌	7	19

XGBoost	真實為漲	真實為跌
預測為漲	22	1
預測為跌	5	21

Accuracy	81.63%
Precision	86.96%
Recall	76.92%
F1-Score	81.63%

Accuracy	86.67%
Precision	95.00%
Recall	73.08%
F1-Score	82.61%

Accuracy	87.76%
Precision	95.45%
Recall	80.77%
F1-Score	87.50%

分類模型

- 最終以5%1D-TF-PCA 資料集表現最佳

SVM Linear	真實為漲	真實為跌
預測為漲	21	2
預測為跌	7	19

SVM rbf	真實為漲	真實為跌
預測為漲	22	1
預測為跌	7	19

KNN	真實為漲	真實為跌
預測為漲	21	2
預測為跌	3	23

Accuracy	81.63%
Precision	90.48%
Recall	73.08%
F1-Score	80.85%

Accuracy	86.67%
Precision	95.00%
Recall	73.08%
F1-Score	82.61%

Accuracy	89.80%
Precision	92.00%
Recall	88.46%
F1-Score	90.20%

分類模型

- 最終以5%1D-TF-PCA 資料集表現最佳

Random Forest	真實為漲	真實為跌
預測為漲	19	4
預測為跌	3	23

Decision Tree	真實為漲	真實為跌
預測為漲	15	8
預測為跌	7	19

Accuracy	85.71%
Precision	85.19%
Recall	88.46%
F1-Score	86.79%

Accuracy	69.39%
Precision	70.37%
Recall	73.08%
F1-Score	71.70%

（四）回測模型分析

資料回測

- 根據資料筆數及分類模型準確度的考量，我們最終使用 0%5D 資料集來進行資料回測

資料集	資料數	Average Accuracy	Average F1-Score	Average Precision	Average Recall
5%1D - PCA - TF	245	82.9%	82.99%	88.81%	78.37%
3%1D - PCA - DF	1932	75.67%	81.31%	73.47%	91.2%
5%5D - PCA - TF	2415	75.54%	77.93%	74.56%	81.76%
0%5D - TF	8520	62.26%	65.34%	62.22%	69.02%

- 最終以 0%5D-TF 資料集，SVM Linaer 分類器進行回測，以F1-Score排序

資料集	分類器	Accuracy	F1-Score	Precision	Recall
0%5D - TF	SVM linear	64.73%	69.20%	63.20%	76.44%
0%5D - TF	Naïve Bayes	63.97%	68.42%	62.68%	75.31%
0%5D - TF	Voting Classifier	65.02%	67.71%	64.90%	70.78%
0%5D - TF	XGBoost	61.62%	67.30%	60.25%	76.22%
0%5D - TF	Logistic Regression	63.85%	66.12%	64.28%	68.06%
0%5D - TF	SVM rbf	62.32%	65.37%	62.41%	68.63%
0%5D - TF	Random Forest	62.91%	65.35%	63.34%	67.50%
0%5D - TF	Decision Tree	58.45%	59.95%	59.89%	60.02%

資料回測

- 每次取前 3 個月的文章為訓練資料預測第 4 個月的看漲看跌文章數

SVM	真實為漲	真實為跌
預測為漲	2127	1652
預測為跌	1549	1281

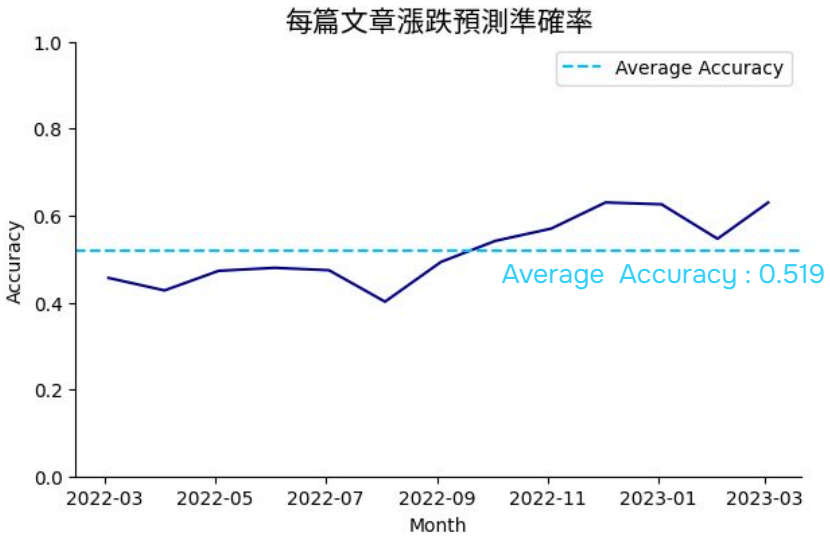

資料回測

- 利用前述分類結果 + SVM 模型，每次取前 3 個月的看漲看跌文章數預測第 4 個月 D + 5 日的股價實際漲跌，若篇數差距小於當天文章 25% 則不出手

出手率 : 72.7%

SVM	真實為漲	真實為跌
預測為漲	71	34
預測為跌	41	58

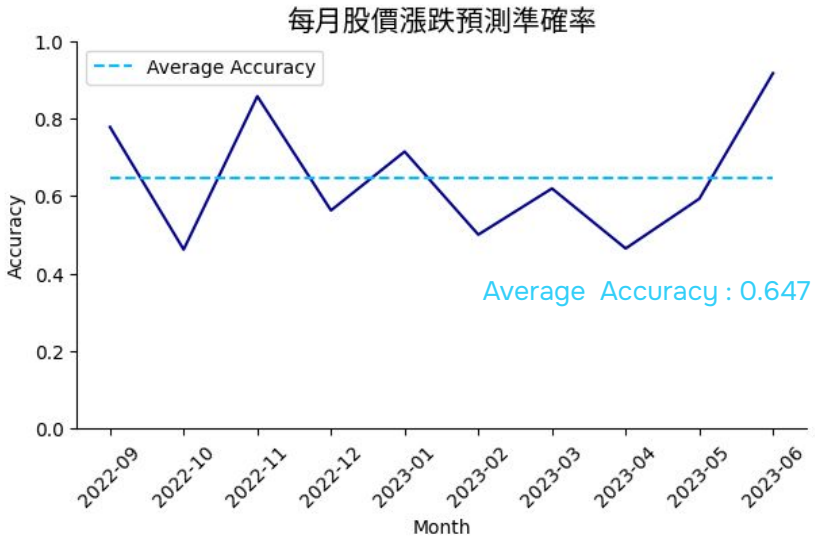

（五）Recap

Recap

選擇標的

聯發科：

- 原始資料量大
- 股價波動大

定義漲跌

製作多種條件類型資料以確認如何定義漲跌

製作價格資料

預先使用 Excel 製作偏好的價格資料格式

文章預處理

對文章進行斷詞、停用詞處理，並計算 TF/DF卡方值，依據結果篩選出最具鑑別力的文字建構向量空間，最後以 PCA 降維

Recap

建立分類器

建立多種分類器模型比較不同資料集與模型之優劣

在指標(F1, AUC...)等表現優異的資料集因**資料筆數少**，不適合回測，因此回測之資料折衷選擇指標表現不那麼好但筆數足夠者

回測模型

以前三個月的文章為訓練資料，預測第四個月的看漲看跌文章數。再使用前述資料預測實際股價漲跌

說明影片連結
https://youtu.be/ZCbJ9R5G8dA

Thanks!