股價漲跌關鍵字及模型預測

大數據與商業分析 期中報告

Apr. 26, 2023, 臺大管二 206 教室

Group 20

蔡宗翰 王士瑋 王奕涵 王昱淮 黃湘婷 邱卉宜

Outline

1. Requirement 1—選股
2. Requirement 1—資料前處理
3. Requirement 1—向量化處理
4. Requirement 2—分類模型
5. Requirement 3—結果回測

Requirement 1

選股—以所有半導體上市上櫃公司為分析對象

臺灣晶圓代工全球市佔

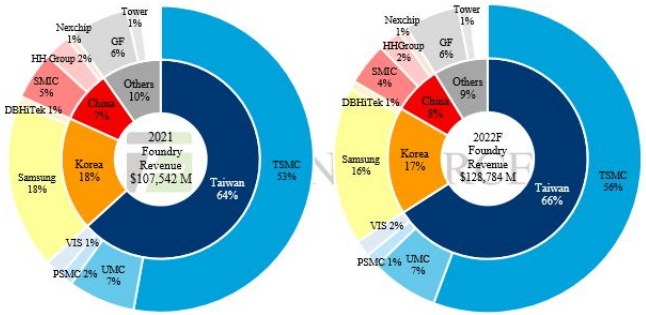

資料來源:TrendForce

各產業新聞提及次數

公司產業	ETF	銀行	保險	半導體	電子商務	存託憑證
討論次數	5034	2242	1907	1550	950	814

選擇產業原因

臺灣2021年整體半導體產值市佔26%，全球排名第二

臺灣股市行情主要受半導體產業漲跌影響

新聞集中，「半導體」相關詞彙被提及次數大於1500次

選擇股票市場中所有上市櫃半導體公司，共174家之股票作為研究對象，並以其收盤價之平均值為分析目標

Requirement 1

資料前處理—以財經新聞發布日後第 3 天的股價漲跌超過5%及1%作為標記標準

(1) 資料選擇

考量論壇與BBS內容多數較短，僅選用財經新聞的文件集，並以 2022年4月1號至2023年3月21號一年內的文章為限

- 刪除標題具有「【公告】」之文章，減少資料量以利後續分析

(2) 漲跌標記

以新聞發布日期後第 3 天的股價作為判斷目標，並以股價漲跌幅度超過「5%」或「1%」為條件，挑選出兩套資料。

- 漲跌幅度超過5% -> 共7183篇看漲新聞、4179篇看跌新聞
- 漲跌幅度超過1% -> 以標題、內容需含有「半導體」字詞為條件，進行文章篩選，最後挑出共 3664篇看漲新聞、3054篇看跌新聞

Requirement 1

向量化處理—使用 monpa 進行斷字，並計算卡方、MI 與 Lift 值以篩選關鍵字

(1) 斷字處理

針對四套文章集分別使用 monpa 套件進行句子斷字，並計算各個字詞的 TF 與 DF 值

(2) 關鍵詞篩選

計算斷詞後各字詞的 TF 卡方值、DF 卡方值、MI 值與 Lift 值，根據各數值排名給予分數並加總平均，挑選出前 1500個字詞作為資料關鍵字

看漲與看跌關鍵字列表		
5%	看漲	矽谷銀行、兔年、漢來、林鑫川、施瓊華、王道銀行、礦山、宇峻、羅智先...
	看跌	張捷、董事、SHEIN、維昱、議價率、友通資訊股份有限公司、SWAP……
1%	看漲	表現、獲利、新台幣、庫存、產業、維持、晶圓、新高、未來、資訊、可望.....
	看跌	iC、2022年、公司、營收、市場、公告、半導體、合併、需求、台北、營運....

向量化處理—以TfidfVectorizer 建立向量空間

(3) 向量空間

利用 sklearn 套件中的 TfidfVectorizer，將 5% 與 1% 漲跌變化之看漲、跌新聞集之關鍵字篩選結果分別建構向量空間，並使用 idf加權

- 以利後續將向量空間資料直接餵入分類模型進行訓練與分析

分類模型訓練與測試準備

- 將看漲與看跌文章隨機分散，分成 80% 訓練資料與 20% 測試資料
- 採用的分類模型：Naïve Bayes (NB), KNN, SVC, Decision Tree, Gradient Boosting

Requirement 2

分類模型—漲跌幅度5%，取用關鍵字1500個

NB	真實為漲	真實為跌
預測為漲	1326	123
預測為跌	426	398
準確率	75.84%	

SVC	真實為漲	真實為跌
預測為漲	1331	90
預測為跌	291	561
準確率	83.24%	

KNN	真實為漲	真實為跌
預測為漲	1300	156
預測為跌	283	534
準確率	80.69%	

Decision Tree	真實為漲	真實為跌
預測為漲	1261	207
預測為跌	220	585
準確率	81.21%	

Gradient Boosting	真實為漲	真實為跌
預測為漲	1334	105
預測為跌	311	523
準確率	81.70%	

SVC 的準確率最高

1. 股票價格的變化受到多種因素影響，且這些因素可能交互作用，對價格的影響是非線性的。
2. 投資者對消息的反應也是影響股票價格變化的一個重要因素。

Requirement 2

分類模型—漲跌幅度1%，取用關鍵字1500個

調降漲跌幅	由於使用5%篩選出的文章集中在少數幾天，可能因為股價波動較小或標準太嚴格，故將篩選條件降至1%以解決資料集集中的問題。

NB	真實為漲	真實為跌
預測為漲	624	89
預測為跌	479	152
準確率	57.74%	

SVC	真實為漲	真實為跌
預測為漲	580	139
預測為跌	315	310
準確率	66.22%	

KNN	真實為漲	真實為跌
預測為漲	485	256
預測為跌	203	400
準確率	65.85%	

Decision Tree	真實為漲	真實為跌
預測為漲	556	175
預測為跌	192	421
準確率	72.69%	

Gradient Boosting	真實為漲	真實為跌
預測為漲	553	198
預測為跌	271	322
準確率	65.10%	

整體準確率相對漲跌幅度5%的資料低了10%以上

Requirement 2

篩選條件降低導致結果不準，使用5%表現較佳

		NB	SVC	KNN	Decision Tree	Gradient Boosting
80/20	5%	**75.84%**	**83.24%**	80.69%	**81.21%**	81.70%
	1%	57.74%	66.22%	65.85%	72.69%	65.10%
交叉驗證	5%	71.61%	80.59%	76.35%	78.89%	80.59%
	1%	58.13%	65.45%	62.30%	62.63%	62.63%

1. 當把漲跌幅度的篩選條件從5%降至1%時，可能會導致許多微小波動的資料被納入模型中，進而影響新聞的漲跌標籤標註及關鍵字篩選，使得模型的預測結果較不準確。相對地，使用5%的資料集建構的模型則表現較佳。
2. 此外，若從交叉驗證分析的結果來看，其準確度與80/20的分割方式相差不大。這意味著在未經精心挑選資料的情況下，整體的準確率不會有太大差異，相對符合真實情況。

Requirement 3

結果回測—測試月份中被篩選出來的文章，測試文章標記與預測結果是否一致

回測方式

- 在測試月份中，將被篩選出來的文章按照一天為單位進行漲跌比較，以預測當天的漲跌情況，並計算出其準確率和出手率(判斷為平則不進行交易)。
- 使用Gradient Boosting，並且用 Chi-2 挑特徵，取排名前 2000 的關鍵字

	真實為漲	真實為跌
預測為漲	23	18
預測為跌	8	16
準確率	60.00%	
出手率	95.59%	

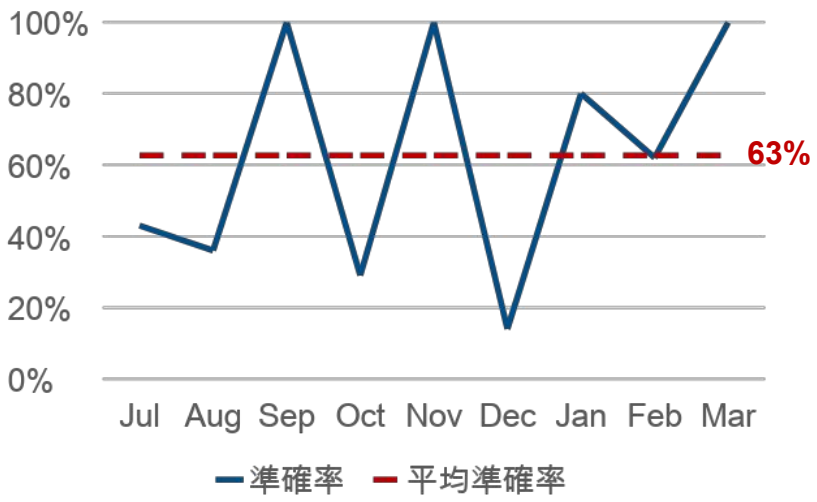

Requirement 3

結果回測—準確率較低主要為測試資料不足導致

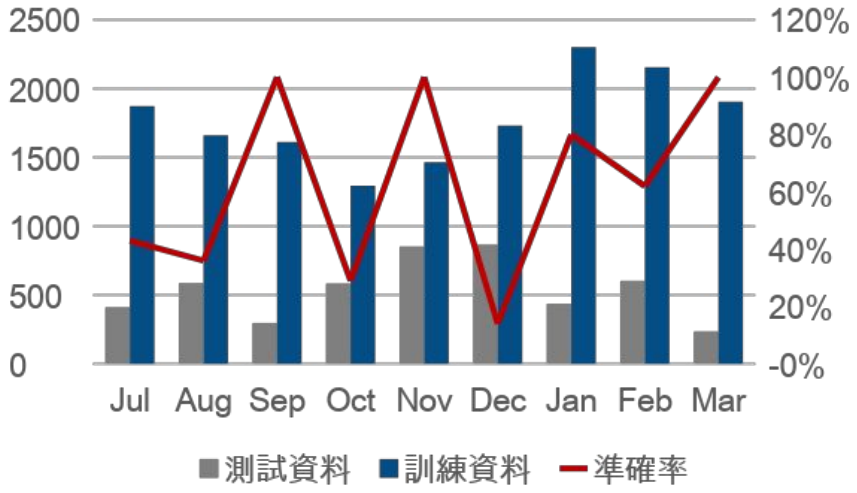

準確率在某些月份高達100%，而某些月份卻低於20%

- 模型準確率低的原因是某些月份的資料較少，訓練資料只能選擇其中部分月份，使得模型在測試資料上預測表現不夠準確。
- 此外，也可能是由於訓練資料不足所導致的 overfitting 現象。

解決方法

1. 收集更多資料，以使得資料集更為均衡，從而避免部分月份資料過少的問題。
2. 嘗試增加特徵工程技術，或者使用正則化技術來降低模型過擬合的風險。此外，也可以使用其他驗證技術來幫助確定模型的最適參數。

影片連結

https://drive.google.com/file/d/1WU2lxPZ6tyNyDJTbcZ5HeAWOvTsHXTSz/view?usp=sharing