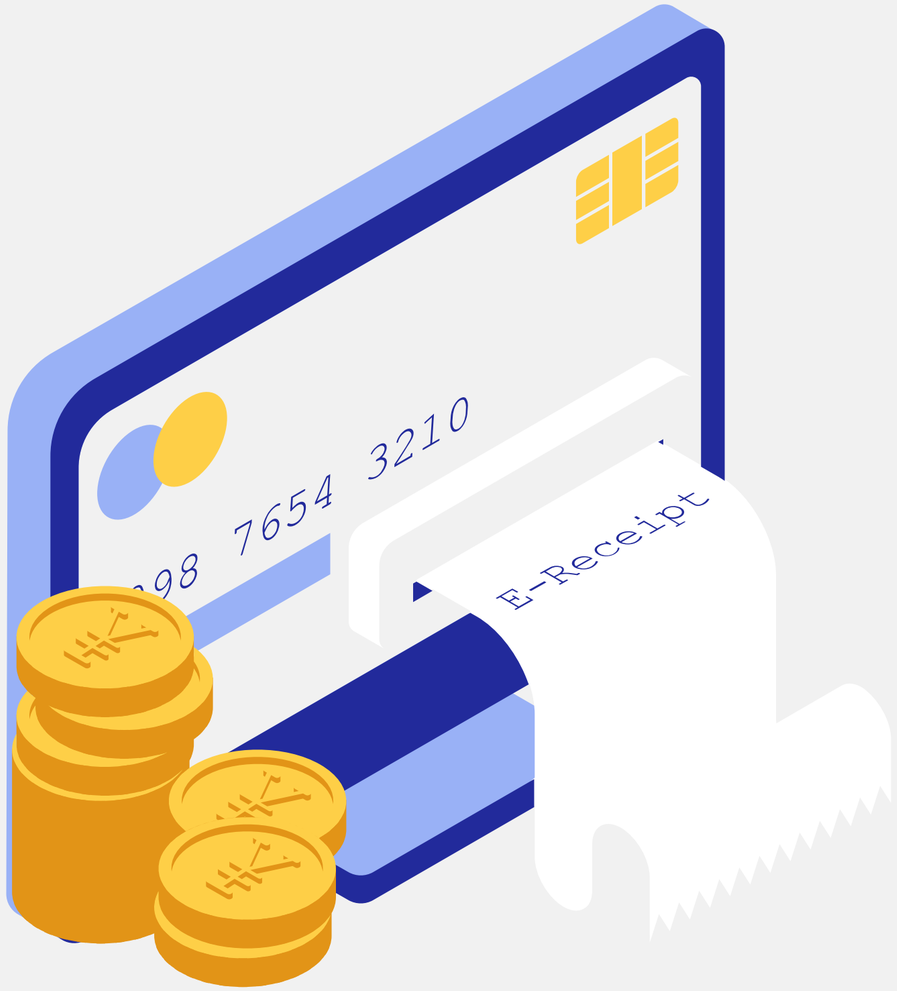

文本關鍵字驅動的股票漲跌預測

大數據與商業分析期中報告

Group 10
蔡承瀚、黃子維、徐舒庭、林杰、許凱傑、鄭昱修

Agenda

01 選股策略

02 資料前處理

03 文本向量化與建立向量空間

04 特徵篩選

05 分類器模型之建構與表現

06 回測模型之建構與表現

為什麼選擇營建股？

- 因房市波動大，營建業成為近年來重點產業
- 討論資料中提及「房市」和「營建」等關鍵字文章數量多
- 營建股和房市走勢呈現正相關

為什麼最後選擇台泥？

- 含有關鍵字「台泥」之文章數量多
- 為營建業上游廠商，屬於營建股
- 2023/1 - 2025/3 間股市波動明顯

資料前處理

資料讀取與欄位選取	讀入news, dcard, mobile01和ptt的相關討論資料
	保留三個欄位：post_time, title, content
關鍵字篩選與排除公告	設定關鍵字：房市、台泥、營建，並保留含有關鍵字之文章
	排除標題中含有「公告」之文章
斷詞與文字清理	使用jieba中文斷詞模組，配合大辭典清除非中英文及數字
	移除stopwords並將token存入content欄位
標記股價資料與分類標籤	從股價資料搜尋D日後最近20天內有的D+n資料
	將兩天的股價差值做為標記標準

文本向量化

- 我們嘗試了以下三種文字向量化方式

TF-IDF	• 使用 **Jieba** 進行中文斷詞 • 計算詞頻與逆文檔頻率來生成向量
text2vec-base-chinese	• 基於 BERT 預訓練的語意編碼模型 • 將完整的文本輸入模型，**自動進行斷詞與語義編碼，產生語義向量（embedding）** • 使用 `pooler_output` 作為最終的文本語意表示
word2vec	• 使用**淺層神經網路的詞向量模型** • 採用 CBOW 架構：根據上下文詞預測中心詞，學習詞的語意向量 • 每個詞都有固定長度的向量表示，可用於詞彙相似度分析或簡單文本表示

向量化方式分析

- 以 SVM 為基礎模型
- 目標：挑選最佳的向量化方式

向量化方法 / 資料集	1% 漲跌幅	2% 漲跌幅	3%漲跌幅
文本數量	6386	1605	219
TF-IDF	0.62	0.74	0.77
Word2Vec	0.55	0.65	0.69
text2vec-base-chinese	0.57	0.63	0.69

特徵挑選

- 我們嘗試了以下三種方式

Chi-Square(卡方檢定)	• 用於評估類別變量之間的獨立性 • 常用於選出與目標變量最相關的特徵，減少無關特徵的維度，適用於離散數據
PCA(主成分分析)	• 一種線性降維技術，通過將數據投影到主成分（方差最大的方向）上 • 保留數據的主要變異信息，降低維度，適合連續數據
Truncated SVD（截斷奇異值分解）	• 通過保留矩陣分解中最大的奇異值和對應向量來近似原始數據 • 適合高維稀疏數據，能有效降低維度並保留主要信息

特徵挑選分析

- 以 **SVM** 為基礎模型
- 目標：挑選最佳的**特徵挑選方式**

向量化方法 / 資料集	1% 漲跌幅	2% 漲跌幅	3%漲跌幅
文本數量	6386	1605	219
Chi-Square(卡方檢定)	**0.78 (k=8000)**	**0.86 (k=1500)**	**0.91 (k=500)**

分類器模型之建構

(1) 將看漲及看跌兩批文章分為訓練資料及測試資料

→ Training - 80% , Testing - 20%

(2) 將資料餵入分類模型訓練並分類

→ 基礎模型：SVM(RBFkernel)、RandomForest、CatBoost
以三種基礎模型建立整合模型：VotingClassifier、StackingClassifier

(3) 嘗試條模型參數進行優化

→ 嘗試方法：Optuna 自動調參、Gridsearch、手動調參 → 最後選擇手動微調訓練權重與SVM模型 C 值

分類器模型之表現 - 1D-1%-TFIDF-CHI2

漲跌文章分布	
看跌文章數量	3163
看漲文章數量	3223

SVM	真實為跌	真實為漲	召回率
預測為跌	446	176	72%
預測為漲	104	552	84%
準確率	78.1%		

RF	真實為跌	真實為漲	召回率
預測為跌	388	234	62%
預測為漲	105	551	84%
準確率	73.5%		

CB	真實為跌	真實為漲	召回率
預測為跌	503	119	81%
預測為漲	338	318	48%
準確率	64.2%		

VC	真實為跌	真實為漲	召回率
預測為跌	427	195	69%
預測為漲	121	535	82%
準確率	75.3%		

SC	真實為跌	真實為漲	召回率
預測為跌	466	156	75%
預測為漲	111	545	83%
準確率	79.1%		

分類器模型之表現 - 1D-2%-TFIDF-CHI2

漲跌文章分布	
看跌文章數量	549
看漲文章數量	1056

SVM	真實為跌	真實為漲	召回率
預測為跌	72	37	66%
預測為漲	5	207	98%
準確率	86.9%		

RF	真實為跌	真實為漲	召回率
預測為跌	62	47	57%
預測為漲	20	192	91%
準確率	79.1%		

CB	真實為跌	真實為漲	召回率
預測為跌	73	36	66%
預測為漲	39	173	82%
準確率	76.6%		

VC	真實為跌	真實為漲	召回率
預測為跌	74	35	68%
預測為漲	19	193	91%
準確率	83.18%		

SC	真實為跌	真實為漲	召回率
預測為跌	466	156	72%
預測為漲	111	545	91%
準確率	84.42%		

分類器模型之表現 - 1D-3%-TFIDF-CHI2

漲跌文章分布	
看跌文章數量	86
看漲文章數量	133

SVM	真實為跌	真實為漲	召回率
預測為跌	11	3	79%
預測為漲	0	30	100%
準確率	93.2%		

RF	真實為跌	真實為漲	召回率
預測為跌	10	4	71%
預測為漲	0	30	100%
準確率	91%		

CB	真實為跌	真實為漲	召回率
預測為跌	12	2	86%
預測為漲	1	29	97%
準確率	93.2%		

VC	真實為跌	真實為漲	召回率
預測為跌	11	3	79%
預測為漲	0	30	100%
準確率	93.2%		

SC	真實為跌	真實為漲	召回率
預測為跌	11	3	79%
預測為漲	0	30	100%
準確率	93.2%		

移動回測模型之建構

(1) 使用1D-1%-TFIDF-CHI資料與Stacking模型，並將個別模型的權重都設定為“Ballanced”

→ 提高模型泛化能力

(2) 每次取D日之前所有的文章作為訓練資料，預測D+1日的股價漲跌

→ 預測範圍為 2024-01 - 2025-01，若當天篇數小於7篇則不預測

(3) 調整 predict_threshold，篇數差距小於當 天文章數 x predict_threshold 則不出手

→ 觀察出手率與準確率之關係

移動回測模型資料分布

年/月	該月有文章天數	該月文章數
2024-01	14	231
2024-02	1	35
2024-03	7	224
2024-04	3	145
2024-05	14	605
2024-06	5	254

年/月	該月有文章天數	該月文章數
2024-07	7	231
2024-08	9	35
2024-09	6	224
2024-10	9	145
2024-11	7	605
2024-12	8	254
2025-01	17	236

資料集中總共有107天擁有文章，其中有十天因為不滿7篇而不納入預測，因此需預測天數共97天

移動回測模型之表現

predict_threshold	總出手率	總準確率
0.4	41.7%	100%
0.3	57.3%	96.4%
0.25	65.2%	95.2%
0	100%	85.4%

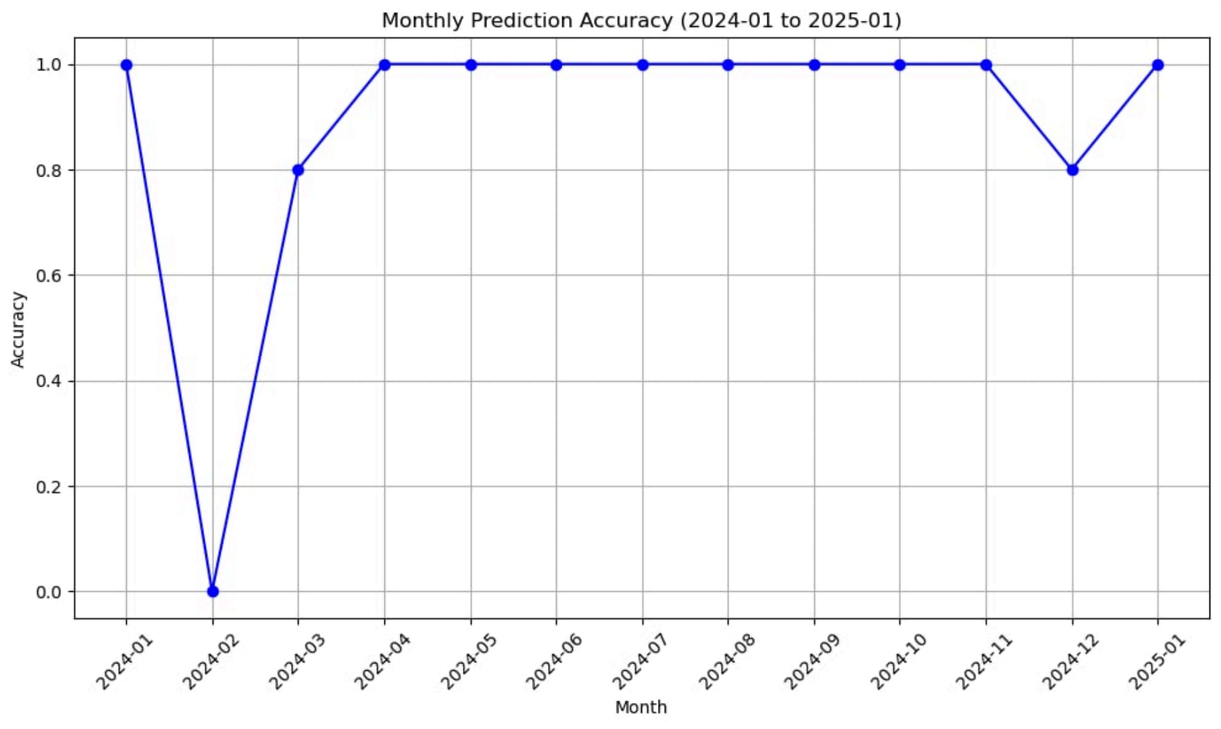

sc	真實為跌	真實為漲
預測為跌	29	2
預測為漲	1	30

predict_threshold = 0.25

準確率□：95.2%

出手率：65.2%

說明影片連結 ：

https://drive.google.com/drive/folders/1SfsIFSnwrgsc82nbVt5GSb1-_U6RPGZT?usp=drive_link

Thanks